Trabajo práctico N°1

Llamar la atención al usuario: diseño de un mínimo viable para un video breve a partir de un PDF conceptual

Institución: Universidad Autónoma de Entre Ríos – Facultad de Ciencia y Tecnología (FCyT) - Oro Verde

Carrera: Licenciatura en Sistemas de Información

Asignatura: Interfaz Hombre Máquina

Profesores: Mg. Díaz, Santiago R. BioIng. Hadad, A.

Alumno: Götte, Brian (bngotte@gmail.com); Murguia, Enzo (murguiaenzo@gmail.com)

Fecha de entrega: 20/04/2026

Año: 2026 – 5to. Año

1. INTRODUCCIÓN

En este trabajo se realizará la ingeniería de producción de un solo vídeo breve orientado a retener la atención al usuario con TDAH, proponiendo cómo debería construirse, con qué fases, modelos de inteligencia artificial y decisiones a tomar.

Para comenzar, se redactan las características clave a tener en cuenta para la realización del proyecto.

1.1. ¿Qué es el TDAH?

El trastorno por déficit de atención e hiperactividad (TDAH) es un trastorno del desarrollo neurológico que determina cómo se desarrolla y funciona el cerebro de una persona. Afecta específicamente las áreas cerebrales que regulan la función ejecutiva, impactando fuertemente la capacidad de un individuo para planificar, organizar tareas, mantener la atención y controlar sus emociones e impulsos

Sus síntomas principales se agrupan en tres grandes categorías: falta de atención, hiperactividad e impulsividad. Es una afección médica neurobiológica por la cual la persona requiere de apoyo y estrategias para manejar sus síntomas de manera exitosa (Instituto Nacional de la Salud Mental, 2023).

1.2. Relevancia del TDAH en Interfaz Hombre Máquina

El diseño de la Interfaz Hombre-Máquina (IHM) adquiere una gran relevancia frente al TDAH porque las estrategias de diseño de interacción (IxD) tienen la capacidad de influir significativamente en el compromiso y enfoque del usuario.

Esta condición provoca deficiencias importantes en la memoria de trabajo, el control inhibitorio y la atención sostenida, por lo que existe una gran necesidad de desarrollar estrategias y soluciones de interacción centradas en el usuario orientadas específicamente a aumentar el lapso de atención de estas personas.

1.3. ¿Por qué llamar la atención del usuario es un problema de diseño?

Llamar y retener la atención del usuario se ha convertido en un problema técnico y ético central para el diseño de interfaces porque, en la actual "Economía de la Atención", el enfoque de las personas es el recurso más escaso y valioso.

El principal desafío de diseño radica en que los principales modelos de negocio buscan retener al usuario empleando patrones adictivos (como notificaciones continuas o el scroll infinito) que explotan la impulsividad, mientras que el bienestar del usuario exige interfaces que le permitan cumplir sus objetivos sin ser secuestrado por distracciones.

Por consiguiente y respondiendo la pregunta, el reto de diseño recae en crear un sistema que compense la falta de motivación ofreciendo retroalimentación inmediata, logrando un balance que sea simple pero a la vez estimulante, predecible y guiado para no agotar la atención del usuario.

1.4. Recursos utilizados para retener la atención

Se ha realizado una investigación respecto a lo dictado en la cátedra acerca de la retención del espectador los conceptos psicológicos que se pueden aplicar. Cada uno de estos elementos se han utilizado al menos una vez en alguna de las fases (escritas entre paréntesis) para asegurar cumplir el objetivo de retener al espectador con TDAH y que el mensaje se comunique con éxito.

- **Atención selectiva**: capacidad de enfocarse en estímulos relevantes mientras se filtran ruidos y distracciones del entorno.
- **Saliencia visual**: elementos que logran destacar visualmente en la interfaz para capturar rápidamente el enfoque del usuario (primera escena, pulsión de muerte).
- **Novedad**: cambios y estímulos visuales nuevos utilizados para evitar el aburrimiento y resetear la atención. (cambio de escena a neutro y pulsión de vida).
- **Contraste**: diferencia visual clara entre elementos, empleada para resaltar información importante y guiar visualmente (cambio de paleta de colores, sonido y elementos de las escenas).
- **Carga cognitiva**: esfuerzo mental necesario para que el cerebro procese información y entienda una interfaz (narrativa escrita y en forma auditiva).
- **Memoria de trabajo**: capacidad ejecutiva para retener y manipular información temporalmente al resolver una tarea (narrativa escrita y en forma auditiva, con ayuda visual para entender el mensaje de estudio).
- **Motivación**: impulso fuertemente asociado a la dopamina que dirige el comportamiento hacia un objetivo (el “hook” utilizado y la forma de dar el mensaje positivo).
- **Recompensa inmediata**: gratificación o retroalimentación rápida tras una acción, fundamental para sostener el interés continuo (cambio de escena rápido).
- **Emoción**: respuesta afectiva subyacente que impacta de manera directa en la autorregulación y el aprendizaje (se transmite mediante los sonidos, colores y elementos de la escena).
- **Legibilidad**: claridad visual de los textos mediante tipografías, espaciado y contraste que facilitan su lectura (elecciones con respecto al texto).
- **Jerarquía visual**: Organización del contenido por nivel de importancia para ayudar al cerebro a interpretar datos rápidamente.
- **Reducción de fricción**: minimización de distracciones y esfuerzo cognitivo requeridos para que el usuario tome decisiones fácilmente.

2. ANÁLISIS DEL PDF

2.1. Idea a comunicar

Se elige comunicar un beneficio público que brinda el gobierno nacional argentino para los estudiantes de nivel obligatorio y superior: la beca “Progresar”.

Para ello, se ha recolectado información de la página gubernamental y descargados los documentos en PDF del corriente año 2026 con la información que respecta a la beca obligatoria y superior.

Para el caso presentado, el público objetivo son los estudiantes de nivel obligatorio y superior, a quienes está destinada la beca. El objetivo del vídeo es que sepan de su existencia y se inscriban en la misma.

2.2. Arquitectura

Para llevar adelante este proyecto, se diseñó una “arquitectura” de trabajo híbrida, en la cual se delega parte del trabajo a la inteligencia artificial.

2.2.1. Modelos de IA generativa elegidos

- **LLM: Llama-3.2-11b**: seleccionado por su relación entre rendimiento y eficiencia computacional. Al ser un modelo de 11 billones de parámetros, ofrece la precisión semántica y la capacidad de seguimiento de instrucciones necesarias para estructurar el storyboard y aplicar los conceptos psicológicos (pulsión de muerte/vida), pero manteniendo una latencia baja y un costo de inferencia prácticamente nulo.
- **Video: VEO3.1 FAST**: elegido por ser el modelo del estado del arte de Google para generar vídeo. Usando la variante "FAST" permite una iteración rápida y reduce drásticamente los tiempos de procesamiento computacional y costos. Esta velocidad es vital para generar, evaluar y re-generar los fragmentos de video.
- **Imágenes: Gemini Nano Banana 2**: elegido específicamente para la fase de generación de imágenes de referencia (keyframes). Su arquitectura ligera y de alta velocidad de respuesta facilita la creación de los anclajes visuales a muy bajo costo, agilizando el flujo de preproducción visual.

2.2.2. Codificación y git del proyecto

El código de esta arquitectura funcional se encuentra programado en Python y utiliza el servicio “Groq” para acceder al LLM. Se puede acceder a él en GitHub, a través del siguiente enlace: https://github.com/gonicdroid/ihm_tdah_video_ai

Para ejecutarlo, es necesario crear el entorno virtual e instalar las dependencias, como se encuentra indicado en el README del proyecto.

2.2.3. Primer fase: ingesta y comprensión del PDF conceptual

Se deben de colocar en la carpeta “assets” del proyecto los documentos que se van a utilizar como entrada.

Paso seguido, se ejecuta el proyecto con el comando “python3 main.py”, donde se procesan los archivos obteniendo la información de estos.

Por último, se anexa a la información un prompt que le indica al modelo de LLM qué debe hacer. Este prompt contiene, en forma resumida:

- Un rol: “analista experto en procesamiento de información y psicología de la atención”;
- Un objetivo: “extraer y estructurar la información...”
- Información resumida de cómo se desarrolla el vídeo: Pulsión de muerte (Thanatos), Neutro y Pulsión de Vida (Eros).
- Indicación de qué elementos se deben extraer del documento (tema central, tres ideas importantes, etc) y el formato de devolución del JSON.
- Una indicación para redactar 3 “hooks” o “ganchos” para que el usuario elija el más adecuado, el cual se usará como primera escena del vídeo.

2.2.4. Segunda fase: selección del mensaje de atención

Con la información recolectada anteriormente de los documentos, el sistema genera los tres posibles hooks. El usuario elige el que desea para continuar con la generación.

Estos hooks son creados por el modelo siguiendo instrucciones estrictas, basadas en lo investigado y dado en clase sobre el TDAH, utilizando como recurso la “pulsión de muerte”.

Se adjunta captura de pantalla de la salida del comando, como ejemplo:

```
(venv) gonic@rzn:~/Documentos/GitHub/ihm_tdah_video_ai$ python3 main.py
[INGESTA] Extrayendo datos de: Progresar_Info2026_web.txt...
[INGESTA] Extrayendo datos de: brief_progresar_obligatorio_1ra_convocatoria_2026_1.pdf...
[INGESTA] Extrayendo datos de: brief_progresar_superior_2026_baja.pdf...
Ejecutando Fases 1 y 2: Síntesis y Generación de Opciones...

==================================================
 INTERVENCIÓN HUMANA REQUERIDA (Fase 2)
==================================================
La IA generó los siguientes ganchos atencionales. Selecciona el más adecuado:

[1] Si no terminas tus estudios, podrías quedarte sin opciones para tu futuro.

[2] La falta de educación puede significar una vida de pobreza y limitaciones.

[3] ¿Qué pasaría si no tienes la oportunidad de seguir tus sueños por falta de recursos?

Ingresa el número de tu elección (1, 2 o 3):
```

3. DISEÑO DEL VÍDEO

Para realizar esta etapa, se definió un modelo a seguir, así como diferentes recursos y técnicas que, según lo investigado, permiten obtener y mantener la atención del usuario al que va dirigido.

3.1. Tercera fase: Traducción psicológica del mensaje

Se definieron los siguientes recursos:

- **Contraste visual y ritmo de edición**. El vídeo contiene 3 escenas clave, empezando con la pulsión de muerte (4 segundos) para generar "alerta, la pérdida o la urgencia", continuado del "neutro" (4 segundos) para preparar al usuario a la pulsión de vida, donde se le entregan las buenas noticias (6 segundos).
- **Texto breve y de alto impacto**. El modelo genera texto corto, condicionado por una cantidad máxima de palabras que no saturen la memoria del usuario y quepan en los segundos del vídeo.
- **Reducción de carga cognitiva**. el texto y el audio del vídeo dicen exactamente lo mismo, reforzando la llegada del mensaje y reduciendo la carga cognitiva.
- **Paleta de colores**: se definió una paleta de colores que se utilizará en cada escena, evaluadas para causar el impacto necesario de cada fase. Esta es:
    - Rojo Carmesí, Gris Antracita, Amarillo Alerta para la pulsión de muerte.
    - Gris Azulado, Blanco Roto, Cian Suave para el neutro.
    - Verde Esmeralda, Azul Brillante, Amarillo Sol para la pulsión de vida.
- **Sonidos de fondo**: la frecuencia y el estilo del sonido de fondo cambia según la fase del vídeo, para generar inmersión y apoyar al impacto.
    - Thanatos: sonido que genere urgencia a través del ritmo, ej: latido acelerado, tictac rápido de reloj.
    - Neutro: tonos bajos y suaves, como un sonido ambiental tranquilo.
    - Eros: melodías ascendentes o sonidos que evoquen positividad y alivio, como un arpegio brillante o un sonido de campana suave.

3.2. Cuarta fase: Generación del storyboard

Siguiendo las indicaciones mencionadas anteriormente, además de ciertas instrucciones extra, se instruye al lenguaje para generar escenas ultra descriptivas que mencionan qué debe pasar exactamente en el vídeo, separando las instrucciones en rangos de 2 segundos. Esta decisión se toma para evitar alucinaciones en el modelo generador de vídeo, obteniendo resultados más realistas.

El resultado son las instrucciones para ingresar a un modelo de generación de vídeo, contemplando un hook inicial, el desarrollo de la idea y un cierre. Este resultado puede consultarse abriendo el archivo "/outputs/evidencia_fases_3_4_storyboard.json" en el proyecto.

Además de este resultado, se obtienen en un formato “humano” los archivos de texto denominados “prompts_keyframes” y “prompts_video”.

Por último, se utiliza un generador de voces y se obtienen 3 archivos mp3 que le dan voz a cada una de las narraciones de las escenas.

3.3. Quinta fase: generación de fotogramas clave

Se utiliza un modelo de generación de imágenes para generar los fotogramas clave que luego serán ingresados en el modelo de generación de vídeo. Esta tarea debe ser llevada a cabo manualmente por el usuario.

El LLM proporciona el prompt directo para ingresar en el generador de imágenes en el archivo “prompts_keyframes.txt”, en el cual ya se deja claro la paleta de colores a utilizar para cada escena (mencionados anteriormente) y el estilo visual del vídeo (“estética hiperrealista, cinematográfica y limpia, optimizada para no sobrecargar la atención”).

Se ha utilizado “Gemini Nano Banana 2” para la generación de los fotogramas clave de las escenas. Se puede realizar retoques en los prompts y configuraciones manuales para ajustar el resultado a lo que se espera.

Los dos fotogramas claves obtenidos fueron los siguientes:

-

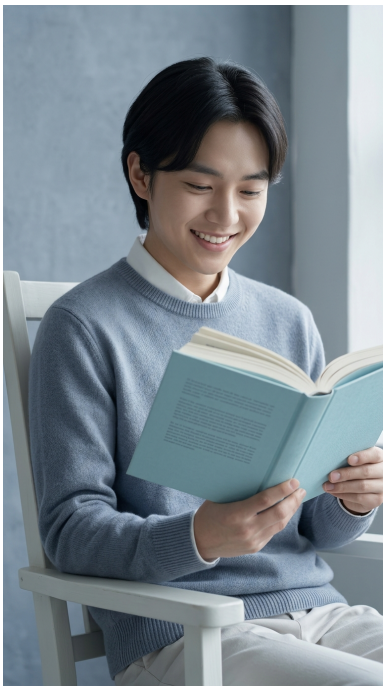

3.4. Sexta fase: generación del vídeo

Se utilizó la herramienta “Google Flow” para realizar las imágenes con el modelo Nano Banana, y luego estas mismas imágenes fueron seleccionadas en la herramienta para crear el vídeo, usando el modelo “Veo 3.1 Fast”.

Además de las imágenes, se utilizó el prompt del archivo generado “prompts_video” para la generación e indicación de lo que debía pasar en cada escena.

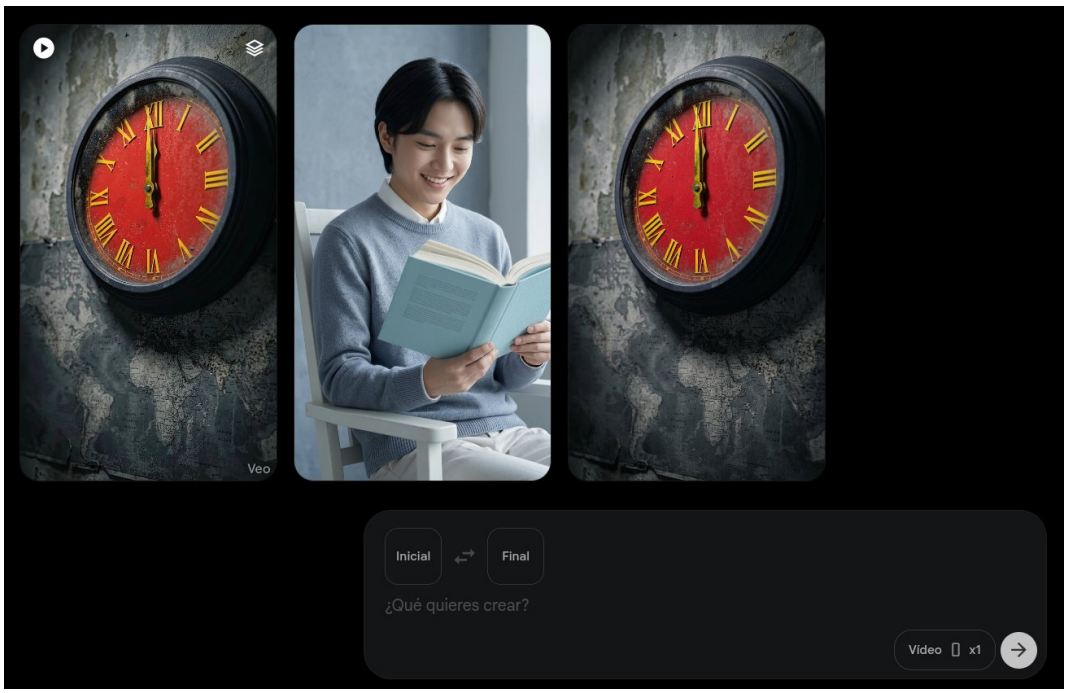

3.5. Séptima fase: voz y audio

La voz se ha generado anteriormente en la fase cuarta, ya que el modelo generador de vídeo es escencialmente bueno para generar vídeo, y no para generar texto o voces. Las voces generadas repiten exactamente lo mismo que se va leer en pantalla.

En cuanto al audio, debido principalmente a una limitación de las API disponibles de forma gratuita, se ha utilizado el mismo modelo de vídeo, en el cual la instrucción de qué sonido emplear para cada escena está dada por “sonido_de_fondo” del archivo “/outputs/evidencia_fases_3_4_storyboard.json”.

3.6. Última fase: ensamble de las diferentes partes generadas

Obtenido el vídeo en la fase anterior, se debe colocar en la carpeta “outputs” con el nombre “video_unico.mp4”. Posteriormente, ejecutando la función “python3 ensamblador.py”, se ensambla el vídeo final por código y se añade el texto en pantalla. Para esto último, se han tomado las siguientes decisiones para aumentar la retención del espectador:

- Letras grandes que ocupan un espacio considerable en la pantalla.
- Se utiliza la fuente “Lexend”, diseñada exclusivamente para reducir el estrés visual y mejorar la velocidad de lectura.
- Orientado a reducir el estrés visual, el texto está sobre un fondo oscuro que facilita la lectura.

3.6.1. Control de calidad

Culminada la generación del vídeo, se deben de evaluar el contenido siguiendo una serie de criterios: idea única, ortografía, claridad de escena, atención inicial, audio, saturación visual, pertinencia del contenido.

Utilizando la herramienta “ChatGPT Evals” y críticas propias, se resuelve el control de calidad con la siguiente tabla:

Criterio	Evaluación	Puntaje (1-10)	Observaciones
Idea única	Sí	9	Mensaje consistente en todo el video.
Ortografía	Correcta	10	Sin errores.
Claridad de escena	Alta	9	Imágenes claras y coherentes.
Atención inicial	Alta	9	Impacto visual fuerte al inicio, podría ser un segundo más.
Audio entendible	Sí	7	La voz podría sonar más natural.
Saturación visual	Baja	9	Diseño limpio.
Contenido apropiado	Sí	10	Mensaje educativo adecuado.

4. INGENIERÍA POR FASES

4.1. Ventajas del enfoque por fases

La principal ventaja del enfoque por fases es el **mantenimiento de la consistencia visual** al generar el vídeo, ya que al dividirlo en fragmentos cortos, el modelo tiene un punto de partida claro evita que los elementos en pantalla se deformen o desaparezcan.

En segundo lugar, se obtiene la ventaja de la **separación de responsabilidades**, que sortea las debilidades actuales de los modelos generativos audiovisuales. Al manejar el texto y el audio por fuera del modelo de video, se evitan alucinaciones textuales y se logra una edición precisa del mensaje.

Por último, el **control de flujo interactivo** en el cual un humano es partícipe de las elecciones más importantes del proceso como la elección del hook y la generación de los fotogramas clave a utilizar para el vídeo. Esto garantiza que el estímulo atencional inicial sea el más efectivo para un usuario con TDAH.

4.2. Riesgos de usar un solo prompt

Los riesgos principales se resumen en:

- **Sobrecarga del modelo** (Alucinaciones): si se utiliza un prompt único con demasiado detalle o requerimientos simultáneos, la IA "no sabe por dónde arrancar" y tiende a desviarse del objetivo o alucinar.

- **Pérdida de coherencia temporal**: al pedirle a un modelo que genere una secuencia larga de forma continua, la información visual se degrada rápidamente, perdiendo la consistencia de la escena inicial.

4.3. Mejoras futuras en el código

Por una limitación principalmente económica de las API de generación de imágenes y video, no se pudo integrar en el proceso de creación las imágenes y el vídeo. Esto hubiera permitido darle directamente al usuario las opciones en vez de que deba generarlas manualmente.

5. BIBLIOGRAFÍA

- Instituto Nacional de la Salud Mental. (2023). *Conocimientos sobre el TDAH: Lo que usted necesita saber*. NIH MedlinePlus Magazine.